



PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO

Especialização em Ciência de Dados e Analytics

MVP em Engenharia de Dados

Pipeline de Dados da Tríade Sombria (SD3) no Databricks

Ligia Assis

Repositório: github.com/ligia-soares-ds/sd3-lakehouse-pipeline

Setembro de 2026

Sumário

1. Contexto de Negócio e Perguntas (Etapa 2 e 4.1)	3
1.1 Problema.....	3
1.2 Perguntas de negócio.....	3
1.3 Fonte, licença e consentimento	3
1.4 Estrutura dos dados brutos	4
2. Carga dos Dados (Etapa 4.2)	4
3. Modelagem e Catálogo de Dados (Etapa 4.3)	5
3.1 Modelo escolhido	5
3.2 Catálogo de Dados	5
4. Pipeline de Dados (Etapa 4.4).....	7
Principais transformações	8
5. Qualidade de Dados (Etapa 4.5)	9
6. Análise de Dados (Etapa 4.5).....	10
Pergunta 1 — Intensidade e distribuição dos traços	10
Pergunta 2 — Proporção com escore elevado.....	11
Pergunta 3 — Associação entre pares de traços.....	11
Pergunta 4 — Perfis de combinação	13
Pergunta 5 — Itens mais endossados	14
Pergunta 6 — Diferenças entre grupos	15
Discussão geral.....	16
Limitações	16
7. Autoavaliação	16
Objetivos atingidos.....	16
Dificuldades encontradas	17
Sobre o processo.....	17
Trabalhos futuros.....	17
8. Referências.....	17

(Clique com o botão direito sobre o sumário e escolha "Atualizar campo" para gerar os números de página.)

1. Contexto de Negócio e Perguntas (Etapa 2 e 4.1)

1.1 Problema

A tríade sombria reúne três traços de personalidade socialmente aversivos: maquiavelismo, que é um estilo interpessoal manipulador e estratégico; narcisismo, marcado por grandiosidade e busca de admiração; e psicopatia, ligada a impulsividade e baixa empatia. Todos fazem parte do espectro normal da personalidade e aparecem em alguma medida em qualquer pessoa, o que afasta leituras maniqueístas ou patologizantes (Coutinho, 2026).

Os três traços são distintos, mas se sobrepõem bastante. A literatura descreve um núcleo comum, chamado fator D, ligado à tendência de maximizar benefícios pessoais às custas de terceiros. Metanálises discutidas por Coutinho (2026) vão além e sugerem que o maquiavelismo talvez seja uma variação da psicopatia, enquanto o narcisismo aparece como o traço mais independente dos três.

Objetivo: compreender como os traços da tríade sombria se distribuem e se combinam em uma amostra ampla de respondentes online do Short Dark Triad (SD3), identificando quais traços aparecem com mais intensidade e quais costumam vir juntos.

Nota ética: os traços da tríade sombria (maquiavelismo, narcisismo e psicopatia) são tratados aqui como traços de personalidade dimensionais e subclínicos, presentes em todas as pessoas em algum grau. Este projeto é exclusivamente descritivo, trabalha apenas com dados anônimos e agregados e não tem qualquer finalidade diagnóstica.

1.2 Perguntas de negócio

- 1. Qual dos três traços apresenta os escores médios mais altos, e como é a distribuição de cada um?
- 2. Que proporção dos respondentes apresenta escore elevado em cada traço?
- 3. Quais pares de traços apresentam maior associação entre si?
- 4. Quantos respondentes apresentam os três traços elevados simultaneamente, e como se distribuem os perfis com apenas um ou dois traços elevados?
- 5. Quais itens do questionário são mais endossados dentro de cada traço?
- 6. Existem diferenças nos escores entre grupos de respondentes (país de acesso ou origem do acesso)?

Critério de escore elevado: o SD3 não tem ponto de corte diagnóstico. Adotei como elevado o escore acima do percentil 75 da própria amostra, calculado separadamente para cada traço.

Hipótese prévia, registrada antes da análise: esperava que maquiavelismo e psicopatia fossem o par mais associado.

1.3 Fonte, licença e consentimento

- Origem: Open-Source Psychometrics Project (openpsychometrics.org/_rawdata), respostas ao teste online do SD3.
- Espelho utilizado para download: Kaggle — [lucasgreenwell/short-dark-triad-responses](https://www.kaggle.com/lucasgreenwell/short-dark-triad-responses).
- Instrumento: SD3 (Paulhus & Jones, 2011), 27 itens, 9 por traço, escala Likert de 5 pontos (1 = discordo; 3 = neutro; 5 = concordo).

Licença: a página do dataset no Kaggle declara Database: Open Database (ODbL), Contents: Database Contents License (DbCL). Na prática, a base pode ser usada, modificada e

compartilhada livremente, inclusive para fins acadêmicos, desde que atribuída à fonte original e mantida sob a mesma licença.

Consentimento: conforme o codebook que acompanha os dados, foram incluídos apenas participantes que indicaram que suas respostas eram precisas e que concordaram com o uso delas em pesquisa. Os dados são anônimos.

1.4 Estrutura dos dados brutos

Arquivo data.csv, separado por tabulação, com 18.192 registros e 29 colunas:

Coluna	Descrição	Tipo original
M1–M9	Itens de maquiavelismo	inteiro (1–5; 0 = não respondido)
N1–N9	Itens de narcisismo	inteiro (1–5; 0 = não respondido)
P1–P9	Itens de psicopatia	inteiro (1–5; 0 = não respondido)
country	País inferido por geolocalização de IP (MaxMind GeoLite)	texto
source	Origem do acesso: 1 = página inicial, 2 = busca no Google, 3 = outra	inteiro

O download inclui também o arquivo codebook.txt, com o enunciado de cada item e a descrição das variáveis técnicas.

2. Carga dos Dados (Etapa 4.2)

A coleta foi automatizada com a API do Kaggle, pela biblioteca kagglehub, dentro de um notebook do Databricks Free Edition. Preferi a API ao upload manual para que o pipeline pudesse ser repetido do começo ao fim: quem executar o notebook obtém os mesmos dados, sem depender de nenhum passo feito à mão.

O kagglehub grava os arquivos no armazenamento temporário do cluster, que se perde quando a sessão reinicia. Por isso copio os arquivos em seguida para um Volume do Unity Catalog, em /Volumes/dark_triad/bronze/raw_files/sd3. Todo o projeto fica em um catálogo próprio, o dark_triad, com um schema para cada camada da Arquitetura Medalhão: bronze, silver e gold.

Script: notebooks/01_ingestao.py, disponível no repositório.

```
▶ 17 hours ago (6s) 9

import shutil

destino = "/Volumes/dark_triad/bronze/raw_files/sd3"
os.makedirs(destino, exist_ok=True)

for arquivo in os.listdir(path):
    origem_arquivo = os.path.join(path, arquivo)
    if os.path.isfile(origem_arquivo):
        shutil.copy(origem_arquivo, destino)

print("Arquivos persistidos no Volume:")
for arquivo in os.listdir(destino):
    tamanho_mb = os.path.getsize(os.path.join(destino, arquivo)) / (1024 * 1024)
    print(f" - {arquivo} ({tamanho_mb:.2f} MB)")

Arquivos persistidos no Volume:
- data.csv (1.04 MB)
- codebook.txt (0.00 MB)
```

Figura 1 — Arquivos persistidos no Volume do Unity Catalog

3. Modelagem e Catálogo de Dados (Etapa 4.3)

3.1 Modelo escolhido

Adotei um Esquema Estrela na camada gold. São duas tabelas fato, uma no grão de resposta a item e outra no grão de respondente, cercadas por três dimensões: dim_item, dim_respondente e dim_perfil.




Figura 2 — Catálogo dark_triad no Unity Catalog, com os schemas e tabelas de cada camada

3.2 Catálogo de Dados

gold.dim_item — os 27 itens do SD3. Linhagem: construída a partir do codebook do dataset.

Campo	Descrição	Tipo	Domínio
id_item	Código do item	string	M1–M9, N1–N9, P1–P9
traco	Traço medido	string	Maquiavelismo, Narcisismo, Psicopatia
texto_item	Enunciado original do item	string	texto livre
invertido	Item de pontuação invertida	boolean	true (N2, N6, N8, P2, P7), false

gold.dim_respondente — um registro por respondente válido. Linhagem: silver.sd3_respostas; id gerado no pipeline; origem_acesso decodificada a partir de source.

Campo	Descrição	Tipo	Domínio
id_respondente	Identificador sequencial gerado no pipeline	int	1 a 17.715
pais_acesso	País inferido por IP (não equivale a nacionalidade)	string	códigos ISO de 2 letras
id_origem	Código da origem do acesso	int	1, 2, 3
origem_acesso	Descrição da origem	string	Página inicial, Busca no Google, Outra origem
data_ingestao	Momento da carga na camada bronze	timestamp	—

gold.fato_resposta_item — uma linha por respondente e item. Linhagem: silver.sd3_respostas em formato longo, com inversão aplicada.

Campo	Descrição	Tipo	Domínio
id_respondente	FK para dim_respondente	int	1 a 17.715
id_item	FK para dim_item	string	M1–P9
traco	Traço do item	string	3 categorias
resposta_original	Resposta como fornecida	int	1–5
resposta_corrigida	Resposta após inversão (6 – valor) quando aplicável	int	1–5

gold.fato_escore_respondente — uma linha por respondente. Linhagem: média de resposta_corrigida por traço; indicadores calculados sobre o percentil 75 da amostra.

Campo	Descrição	Tipo	Domínio
id_respondente	FK para dim_respondente	int	1 a 17.715
escore_maquiavelismo	Média dos 9 itens do traço	double	1,0–5,0
escore_narcisismo	Média dos 9 itens do traço	double	1,0–5,0
escore_psicopatia	Média dos 9 itens do traço	double	1,0–5,0
elevado_maquiavelismo	Escore acima de 4,33 (P75)	boolean	true, false
elevado_narcisismo	Escore acima de 3,56 (P75)	boolean	true, false
elevado_psicopatia	Escore acima de 3,33 (P75)	boolean	true, false
id_perfil	FK para dim_perfil	int	0–7

gold.dim_perfil — as oito combinações possíveis de traços elevados.

Campo	Descrição	Tipo	Domínio
id_perfil	Código da combinação (maq×4 + narc×2 + psic)	int	0–7
descricao_perfil	Descrição da combinação	string	de "Nenhum traço elevado" a "Triade completa"
qtd_tracos_elevados	Número de traços elevados	int	0–3




Figura 3 — Descrições de tabela e colunas registradas no Unity Catalog

4. Pipeline de Dados (Etapa 4.4)

O pipeline segue a Arquitetura Medalhão e foi dividido em um notebook por etapa. Essa organização isola cada responsabilidade e permite reexecutar só o trecho que precisa ser refeito.

Notebook	Camada	O que faz
01_ingestao	— → Volume	Baixa os dados via API do Kaggle e persiste no Volume do Unity Catalog
02_bronze	Volume → bronze	Lê o arquivo como veio (todas as colunas como texto) e adiciona metadados de controle
03_qualidade	bronze	Diagnostica completude, consistência, unicidade, acurácia e outliers, sem alterar dados
04_silver	bronze → silver	Tipagem, exclusões documentadas e geração do identificador de respondente
05_gold	silver → gold	Dimensões e fatos, inversão dos itens, escores e perfis
06_analise	gold	Consultas que respondem às perguntas de negócio

O processo também foi orquestrado como uma pipeline ETL no Databricks, com os oito componentes ligados por dependências. Assim o fluxo inteiro roda a partir de um único acionamento.




Figura 4 — Pipeline do Databricks.

Principais transformações

- Metadados de ingestão (bronze): acrescentei `_data_ingestao` e `_arquivo_origem` a cada registro. Servem para rastrear a origem dos dados e não alteram o conteúdo original.
- Tipagem (silver): converti os 27 itens e a coluna `source` para inteiro. Na bronze mantive tudo como texto, porque assim o Spark não descarta em silêncio nenhum valor inesperado na entrada.
- Exclusões (silver): removi respondentes com itens em branco e com resposta uniforme, conforme detalhado na seção de qualidade.
- Formato longo (gold): transformei as 27 colunas de itens em linhas com `stack`. Esse formato permite a junção com `dim_item` e a análise item a item.
- Inversão de itens (gold): apliquei 6 – resposta em N2, N6, N8, P2 e P7. A correção muda os resultados: a psicopatia caiu de 2,98 para 2,81 e o narcisismo subiu de 3,03 para 3,07. Guardei `resposta_original` e `resposta_corrigida` lado a lado, para que a conta possa ser conferida.
- Escores (gold): usei a média dos 9 itens em vez da soma. A média mantém o resultado na escala original, de 1 a 5, e deixa os três traços comparáveis entre si.

```

18 hours ago (6s) 12

(
    df_silver.write
        .format("delta")
        .mode("overwrite")
        .option("overwriteSchema", "true")
        .saveAsTable("dark_triad.silver.sd3_respostas")
)

spark.sql("""
COMMENT ON TABLE dark_triad.silver.sd3_respostas IS
'Camada Silver: respostas ao SD3 tipadas e validadas. Exclui respondentes com itens em branco e com
resposta uniforme nos 27 itens. Um registro por respondente, com identificador gerado no pipeline. Itens
mantidos na pontuação original, sem inversão.'
""")

print("Tabela dark_triad.silver.sd3_respostas criada.")
> See performance \(2\) ✓ Checked for improvements

/databricks/python/lib/python3.12/site-packages/pyspark/sql/connect/expressions.py:1163: UserWarning: WARN WindowEx
pression: No Partition Defined for Window operation! Moving all data to a single partition, this can cause serious
performance degradation.
  warnings.warn(
Tabela dark_triad.silver.sd3_respostas criada.

```

Figura 5 — Tabelas persistidas nas camadas bronze, silver e gold

5. Qualidade de Dados (Etapa 4.5)

Dimensão	Achado	Tratamento na Silver
Compleitude	452 respondentes (2,5%) com ao menos um item em branco	Excluídos
Consistência	Nenhum valor fora do domínio esperado	Nenhum tratamento
Unicidade	59 registros com respostas idênticas a outras	Mantidos
Acurácia	31 respondentes com o mesmo valor nos 27 itens (25 removidos nesta etapa; 6 já haviam saído na completude)	Excluídos
Outliers	136 (maquiavelismo), 291 (narcisismo) e 38 (psicopatia) escores abaixo do limite inferior	Mantidos

Retenção final: 17.715 registros, ou 97,38% da base original.

Compleitude. Não há valores nulos, mas encontrei o valor 0 em 452 respondentes. Como a escala vai de 1 a 5, entendo esse 0 como item não respondido. A maioria deixou um único item em branco, mas 10 registros tinham 17 ou mais itens faltando, sendo 6 questionários completamente vazios. Excluí todos os respondentes com algum item em branco. A perda é pequena, os escores ficam calculados sobre os mesmos 9 itens por traço e não precisei imputar nada.

Consistência. Os itens variam entre 0 e 5, sem nenhum valor fora do esperado, o que sugere que o formulário de origem já restringia as opções. Com a exclusão dos zeros, some o único valor fora da escala.

Unicidade. O dataset não tem identificador de respondente, então avaliei duplicidade pela repetição exata do conjunto de respostas: são 18.133 combinações distintas em 18.192 registros. Olhando os 59 repetidos, todos são padrões extremos, o que indica coincidência entre respostas uniformes e não duplicação técnica. Removê-los descartaria respostas legítimas, então preferi mantê-los.

Acurácia. Encontrei 31 respondentes que marcaram o mesmo valor nos 27 itens: 12 responderam tudo 5, 6 tudo 1, 6 tudo 0, 5 tudo 3 e 2 tudo 4. Quem responde assim não discriminou entre as perguntas, o que compromete a validade individual da resposta, e por isso esses registros saíram. Escalas de traços sombrios são sensíveis ao viés de desejabilidade social e podem ser falseadas de propósito (Coutinho, 2026). Chama atenção que aqui o padrão de resposta máxima tenha sido o dobro do de resposta mínima.

Outliers. Nos escores por traço, os casos extremos ficam todos abaixo do limite inferior. Não há outliers superiores, porque os limites calculados passam do máximo da escala. São escores baixos e possíveis, não erros de medida, então ficaram na base. Descartá-los comprimiria a distribuição justamente na ponta que interessa descrever.

Dimensão	Achado	Tratamento na Silver
Compleitude	452 respondentes (2,5%) com ao menos um item em branco	Excluir esses registros
Consistência	Nenhum valor fora do domínio esperado	Nenhum tratamento
Unicidade	59 registros com respostas idênticas a outras	Manter
Acurácia	31 respondentes com o mesmo valor nos 27 itens	Excluir esses registros
Outliers	136 (maquiavelismo), 291 (narcisismo) e 38 (psicopatia) escores abaixo do limite inferior	Manter

Figura 6 — Consultas de verificação de qualidade executadas sobre a camada bronze

6. Análise de Dados (Etapa 4.5)

Pergunta 1 — Intensidade e distribuição dos traços

Traço	Média	Mediana	Desvio-padrão
Maquiavelismo	3,71	3,78	0,79
Narcisismo	3,07	3,00	0,77
Psicopatia	2,81	2,78	0,81




Figura 7 — Distribuição dos escores por traço

O maquiavelismo lidera com folga, quase um ponto acima da psicopatia numa escala de cinco. Uma explicação possível é que os traços não são igualmente fáceis de admitir. Os itens de maquiavelismo falam de estratégia nas relações e podem soar como prudência ou jogo de cintura. Já os de psicopatia pedem que a pessoa admita crueldade e descontrole, o que custa bem mais caro socialmente. A leitura combina com o que se discute sobre desejabilidade social nessas escalas (Coutinho, 2026).

Pergunta 2 — Proporção com escore elevado

Com o corte no percentil 75, cerca de um quarto da amostra entra como elevado em cada traço, por construção. O que interessa aqui é o escore que cada corte exige: 4,33 no maquiavelismo, 3,56 no narcisismo e 3,33 na psicopatia. Para entrar no quarto superior de maquiavelismo é preciso concordar fortemente com quase todos os itens; na psicopatia, basta ficar perto do ponto neutro. Um corte absoluto igual para os três, digamos acima de 4, deixaria quase ninguém como elevado em psicopatia e distorceria a comparação. Foi por isso que optei por um critério relativo e descritivo.

Pergunta 3 — Associação entre pares de traços

Par de traços	Correlação de Pearson
Maquiavelismo × Psicopatia	0,67

Par de traços	Correlação de Pearson
Narcisismo × Psicopatia	0,57
Maquiavelismo × Narcisismo	0,51

```

correlacoes = [
    ("Maquiavelismo x Psicopatia", escores.stat.corr("escore_maquiavelismo", "escore_psicopatia")),
    ("Maquiavelismo x Narcisismo", escores.stat.corr("escore_maquiavelismo", "escore_narcisismo")),
    ("Narcisismo x Psicopatia", escores.stat.corr("escore_narcisismo", "escore_psicopatia")),
]

display(
    spark.createDataFrame([(par, round(valor, 4)) for par, valor in correlacoes], ["par_de_tracos",
    "correlacao"])
    .orderBy(F.desc("correlacao"))
)

```

> [See performance \(4\)](#) ✓ Checked for improvements

	par_de_tracos	correlacao
1	Maquiavelismo x Psicopatia	0.6726
2	Narcisismo x Psicopatia	0.5667
3	Maquiavelismo x Narcisismo	0.5136

Figura 8 — Matriz de correlação entre os escores dos três traços




Figura 9 – Correlação de Pearson entre os traços.

O par maquiavelismo–psicopatia é o mais associado e confirma a hipótese que registrei antes da análise. O resultado converge com as metanálises discutidas por Coutinho (2026), que apontam o maquiavelismo como possível variação da psicopatia e o narcisismo como o traço mais distinto. Aqui também é o narcisismo que tem as duas correlações mais baixas. E o fato de as três serem altas dá apoio empírico à ideia de fator D.

Na coocorrência os números ficam mais concretos: entre quem tem maquiavelismo elevado, 57,6% também tem psicopatia elevada e 53,1% tem narcisismo elevado. O acaso produziria cerca de 25%, então todos os pares aparecem bem acima do esperado.

Ressalva de método: correlação alta não prova que os construtos sejam a mesma coisa. Parte da associação pode vir do estilo de resposta, já que quem tende a concordar (ou a negar) responde de forma parecida em todos os itens, o que infla as correlações.

Pergunta 4 — Perfis de combinação

Perfil	Respondentes	%
Nenhum traço elevado	10.273	57,99
Apenas narcisismo	1.484	8,38
Triade completa	1.451	8,19
Apenas psicopatia	1.245	7,03

Perfil	Respondentes	%
Apenas maquiavelismo	1.042	5,88
Narcisismo + psicopatia	884	4,99
Maquiavelismo + psicopatia	755	4,26
Maquiavelismo + narcisismo	581	3,28




Figura 10 — Distribuição dos perfis de combinação de traços elevados

A tríade completa é o terceiro perfil mais frequente e aparece à frente de qualquer combinação de dois traços. Se os três fossem independentes, ela seria o perfil mais raro. O que os dados mostram é o oposto: quem pontua alto tende a pontuar alto em tudo.

Pergunta 5 — Itens mais endossados




Figura 11 — Média por item, após correção dos itens invertidos

Os itens mais endossados sugerem que as pessoas admitem com mais facilidade a visão de mundo por trás do comportamento do que o comportamento em si.

No maquiavelismo, o topo fica com os itens mais impessoais: guardar o que os outros não precisam saber (M7, média 4,39, com 89% de concordância), não contar segredos (M1, 4,18) e achar que a maioria das pessoas pode ser manipulada (M9, 4,08). O último colocado é o que assume o autointeresse de forma explícita (M8, 3,17).

Na psicopatia veio a surpresa. O item mais endossado é admitir que se pode ser mau com os outros (P5, 3,72), bem isolado no topo. O menos endossado de todo o instrumento é ser visto como descontrolado (P4, 2,32). Admitir crueldade, portanto, não parece ser o tabu; perder o controle é. O que as pessoas protegem na autoimagem parece ser a agência.

No narcisismo passam os itens socialmente aceitáveis, como gostar de conhecer pessoas importantes (N5, 3,51) e fazer questão do respeito merecido (N9, 3,45). A grandiosidade declarada fica no fim da lista (N4, 2,68; N3, 2,65).

Os itens invertidos se comportam como esperado: depois da correção, N6 (2,90), N2 (2,88) e P2 (2,79) ficam abaixo da média de seus traços. É justamente o efeito que itens reversos buscam captar.

Pergunta 6 — Diferenças entre grupos

As médias por país de acesso variam pouco: maquiavelismo entre 3,42 e 3,92, narcisismo entre 2,66 e 3,22 e psicopatia entre 2,56 e 2,88. Os quatro países com maior volume, Estados Unidos (8.996), Reino Unido (2.724), Canadá (1.182) e Austrália (746), praticamente não se distinguem entre si. Essa variação não permite conclusões sobre populações nacionais: a amostra é autosselecionada, o campo indica o local de acesso por IP e não a nacionalidade, e os volumes são muito desiguais.

A comparação por origem do acesso é mais segura, porque não envolve nenhum grupo social. Quem chegou por busca no Google (2.639) tem as médias mais altas nos três traços (3,78 / 3,22 / 2,92), acima de quem chegou pela página inicial do site (9.646; 3,72 / 3,03 / 2,80) e de quem veio por outra origem (5.430; 3,67 / 3,07 / 2,79). As diferenças são pequenas, mas se repetem nos três traços. Pode ser autosseleção por motivação: quem procura o teste de propósito talvez tenha algum interesse específico no tema.




Figura 12 — Escore médio por origem do acesso ao teste

Discussão geral

Olhando as seis respostas juntas, duas coisas ficam claras. Os três traços se diferenciam bastante em intensidade, mas estão longe de ser independentes uns dos outros.

Na intensidade, a ordem foi sempre a mesma: maquiavelismo na frente, narcisismo no meio e psicopatia por último. A análise item a item ajuda a entender por quê. Os itens mais endossados são os que custam pouco para assumir, e os menos endossados são os que exigem admitir crueldade ou descontrole. Na combinação, os traços aparecem juntos com muito mais frequência do que o acaso explicaria. As correlações são altas, com destaque para maquiavelismo e psicopatia (0,67), e a tríade completa está entre os perfis mais comuns da amostra.

Há uma discussão em aberto na área sobre se esses três traços são mesmo construtos separados, e não tenho como resolvê-la com os dados oriundos de um questionário de autorrelato, respondido online por quem quis responder, analisado de forma descritiva. O que posso dizer é que o padrão encontrado nos 17.715 respondentes dessa amostra é o mesmo descrito por Vize e colaboradores e por Knitter e colaboradores, discutidos em Coutinho (2026) em que maquiavelismo e psicopatia muito próximos entre si e narcisismo um pouco mais à parte.

Do lado da engenharia de dados, o que mais me marcou foi perceber o quanto escolhas técnicas mudam o resultado. Se eu tivesse tratado o 0 como resposta válida, todos os escores cairiam. Sem inverter os cinco itens reversos, dois traços teriam médias erradas. A média no lugar da soma foi o que deixou os traços comparáveis. E o corte no percentil 75 definiu quem entra na conta de escore elevado. Nenhuma dessas decisões é neutra, e é por isso que registrei todas elas ao longo do relatório.

Limitações

- Amostra online e autosselecionada: os resultados descrevem quem procurou o teste, não a população geral.
- Dados de autorrelato, sujeitos ao viés de desejabilidade social, que tende a subestimar os escores.
- O critério de escore elevado é relativo a esta amostra, sem valor diagnóstico.
- O país indica local de acesso por IP, não nacionalidade.
- O SD3 capta predominantemente a faceta grandiosa do narcisismo, deixando de fora a faceta vulnerável.
- Parte da associação entre traços pode refletir estilo de resposta, e não sobreposição real dos construtos.

7. Autoavaliação

Objetivos atingidos

A pergunta central do trabalho, sobre a associação entre os traços, considero plenamente respondida. Calculei as correlações, a hierarquia entre os pares ficou clara e deu para comparar o resultado com a hipótese que eu tinha registrado antes e com o que a literatura recente discute. As perguntas sobre os perfis de combinação e sobre os itens mais endossados também foram bem respondidas.

Já as perguntas sobre a distribuição e sobre a proporção de escores elevados considero respondidas pela metade. Não por falha na execução, mas por um limite do dado: descrever

como os escores se espalham na amostra é diferente de dizer o que um escore significa para uma pessoa. E é essa passagem que um teste online, aplicado sem contexto clínico, não permite fazer. A sexta pergunta foi respondida tecnicamente, mas conclui que os dados não sustentam interpretação sobre populações nacionais. Mantive a análise no relatório porque não poder concluir também é um achado.

Dificuldades encontradas

A parte mais difícil foi a análise, não a construção do pipeline. Interpretar os resultados exigiu recorrer à literatura atual sobre a tríade sombria para não dizer mais do que os dados permitem, e esse trabalho de fundamentação tomou mais tempo do que as transformações.

A decisão mais difícil foi definir o que contaria como escore elevado. O SD3 não tem ponto de corte clínico, então qualquer critério seria uma escolha minha, e essa escolha afetaria todos os resultados seguintes. Fiquei com o percentil 75 da própria amostra. O ponto que mais me chamou atenção não foi o percentual, mas o escore que cada corte exige: 4,33 no maquiavelismo, 3,56 no narcisismo e 3,33 na psicopatia. Estar entre os 25% mais altos significa coisas bem diferentes dependendo do traço.

Assumi esse critério como relativo e descritivo, e essa é também a principal limitação do trabalho: os perfis dizem onde a pessoa está dentro desta amostra, não uma condição clínica. Tratar esses limites como diagnóstico seria justamente a leitura patologizante que a literatura recomenda evitar, já que os traços sombrios são dimensionais e aparecem em todas as pessoas em algum grau (Coutinho, 2026).

Sobre o processo

Definir o tema deu mais trabalho do que eu esperava. Comecei explorando dados de aviação, percebi que o assunto não me mobilizava e migrei para a tríade sombria, procurando algo mais perto da neuropsicologia. A troca custou tempo, mas valeu: trabalhar com um instrumento que eu conheço me permitiu tomar decisões técnicas com fundamento, como identificar os itens de pontuação invertida e entender por que ignorá-los distorceria os escores, em vez de só executar transformações.

Trabalhos futuros

- Agente de IA sobre as tabelas gold, permitindo consultar os resultados em linguagem natural e aproveitando o catálogo de dados já documentado.
- Comparação com o Big Five, usando outro conjunto do mesmo acervo, para situar os traços sombrios em relação a um modelo amplamente consolidado.
- Revisão de literatura mais sistemática, ampliando a fundamentação da discussão e permitindo confrontar os achados com um conjunto maior de estudos.

8. Referências

1. Coutinho, T. V. (2026). Personalidades sombrias: o que dizem as metanálises. In: Associação Brasileira de Psiquiatria; A. G. Silva, & L. F. Malloy-Diniz (Orgs.). PRONEUROPSI Programa de Atualização em Neuropsicologia: Ciclo 1 (pp. 119-46). Artmed Panamericana. (Sistema de Educação Continuada a Distância, v. 2).
2. Databricks. Medallion Architecture e Unity Catalog. docs.databricks.com
3. Open-Source Psychometrics Project. Raw data from online personality tests. openpsychometrics.org/_rawdata